

Домашнее задание №4.

Предлагается потестировать некоторые изученные методы первого порядка на задаче логистической регрессии (вспомнить/познакомиться с тем, что такое логистическая регрессия, можно, например, на [хабре](#) или прочитать в [википедии](#); для выполнения задания это будет необязательно). Пусть $A \in \mathbb{R}^{n \times d}$ — матрица признаков, $y \in \{-1, 1\}^n$ — вектор ответов. Здесь n — число объектов в датасете, d — число признаков. Функцию потерь в логистической регрессии можно записать в следующем виде:

$$Loss_{logreg}(x) = \frac{1}{n} \sum_{i=1}^n \log(1 + \exp(-y_i \cdot (Ax)_i)), \quad (1)$$

где $x \in \mathbb{R}^d$ — вектор параметров (переменные, по которым нужно оптимизировать), $(Ax)_i$ — i -я компонента вектора Ax . Как правило, на практике задачу минимизации функции (1) не решают в чистом виде.¹, а решают регуляризованную задачу

$$Loss_{logreg}(x) + R(x) \rightarrow \min_{x \in \mathbb{R}^d}, \quad (2)$$

где функция $R(x)$ — выпуклая и замкнутая. В этом задании предлагается потестировать некоторые методы оптимизации на задаче (2). Везде далее в этом проекте предлагается рассматривать регуляризатор вида $R(x) = \frac{\mu}{2} \|x\|_2^2$. В таком случае задачу можно переписать в следующем виде

$$f(x) = \frac{1}{n} \sum_{i=1}^n \underbrace{\left(\log(1 + \exp(-y_i \cdot (Ax)_i)) + \frac{\mu}{2} \|x\|_2^2 \right)}_{f_i(x)} \rightarrow \min_{x \in \mathbb{R}^d}. \quad (3)$$

Задание.

- Загрузите ваш любимый датасет для бинарной классификации (датасеты можно загружать из [LIBSVM](#); в `sklearn` есть удобная для этих целей функция `load_svmlight_file`; к заданию прикладывается датасет `mushrooms`, можно использовать его). Обратите внимание, что вектор меток y должен принимать значения из множества $\{-1, 1\}$ (если это изначально не так, то преобразуйте вектор y к нужному виду).
- Докажите, что дважды непрерывно дифференцируемая функция $f(x)$ является L -гладкой тогда и только тогда, когда $\|\nabla^2 f(x)\| \leq L$ для всех $x \in \mathbb{R}^d$. Покажите отсюда, что константу L для функции f можно взять равной $\mu + \frac{1}{4} \max_{i=1, \dots, n} \|A_i\|_2^2$, где A_i — i -я строчка матрицы A .
- Докажите, что константа сильной выпуклости функции $f(x)$ равна μ .
- Имплементируйте следующие методы:
 - Градиентный спуск.
 - Стохастический градиентный спуск.
 - Ускоренный метод Нестерова.

Запустите методы на задаче (3). Для справедливого сравнения методов считайте не число итераций, а так называемое число эпох. Для полноградиентных методов число эпох равняется числу итераций, а для стохастического градиентного спуска число эпох равняется числу итераций, поделённому на n . В таком случае методы сравниваются по числу вычислений градиентов функций f_i (слагаемых в (3)). По оси ординат откладывайте значение функции $f(x)$ и норму градиента $\|\nabla f(x)\|_2$.

Рассмотрите все изученные на семинарах правила выбора шагов для градиентного спуска и для стохастического градиентного спуска.

Запустите методы с разными μ . Рассмотрите случаи с разным числом обусловленности, то есть возьмите $\mu = \frac{L}{10000}, \frac{L}{1000}, \frac{L}{100}, \frac{L}{2}$ и сравните методы в каждом случае.

¹Кстати говоря, неплохое разминочное упражнение — подумайте, почему эту задачу не решают в чистом виде. При всех ли A данная задача имеет решение?